



## Ayudantía 11

# SVM - Support Vector Machines

Por Blanca Romero y Gonzalo Fuentes

8 de noviembre 2024




# ¿Qué es una SVM?



# ¿Qué es una SVM?

Queremos encontrar una **recta** que **separe los datos**


Para luego poder **clasificar** nuevos datos





# ¿Qué es una SVM?

Existen **infinitas** rectas que logran separar los datos:






# ¿Qué es una SVM?

Existen **infinitas** rectas que logran separar los datos:


¿Cómo elegimos la mejor?





# ¿Qué es una SVM?

**SVM** nos permite encontrar la mejor recta:






# ¿Qué es una SVM?

**SVM** nos permite encontrar la mejor recta:

Busca **maximizar** la distancia de los datos **más cercanos a la recta** (de cada clase)

● y ● son los *vectores de soporte*






# ¿Qué es una SVM?

**SVM** nos permite encontrar la mejor recta:

Busca iterativamente para **maximizar d**

Y trabaja siempre con rectas **equidistantes** a los *vectores de soporte*









# ¿Qué es una SVM?

Debemos procurar que cada **nueva recta** considere los **nuevos vectores de soporte** que se podrían generar






# ¿Y si no puedo hacer una clasificación lineal?



## ¿Qué podemos hacer al respecto?




# ¡Transformamos los datos!



Transformamos los datos a un **nuevo espacio geométrico**




# ¡Transformamos los datos!



Así podemos tomar **un plano** para separar los datos



# ¡Transformamos los datos!



La **proyección** del plano es un **segmento** del espacio inicial

# ¿Cómo puedo transformar los datos a otro espacio?




La idea nace de ver SVM dual

$$\max_{\alpha} \sum_{i=1}^M \alpha_i - \frac{1}{2} \sum_{i,j=1}^M y^{(i)} y^{(j)} \alpha_i \alpha_j x^{(i)} \cdot x^{(j)}$$

subject to  $0 \leq \alpha_i \leq C$  for all  $i$ , and  $\sum_{i=1}^M \alpha_i y^{(i)} = 0$ .

# ¿Cómo puedo transformar los datos a otro espacio?



# ¿Cómo puedo transformar los datos a otro espacio?



$$K(x, x') = \langle \phi(x), \phi(x') \rangle$$

Lineal

$$K(x, x') = x^T x'$$

Polinomial

$$K(x, x') = (x^T x' + c)^d$$

RBF

$$K(x, x') = \exp(-\gamma \|x - x'\|^2)$$



# ¿Cómo puedo transformar los datos a otro espacio?

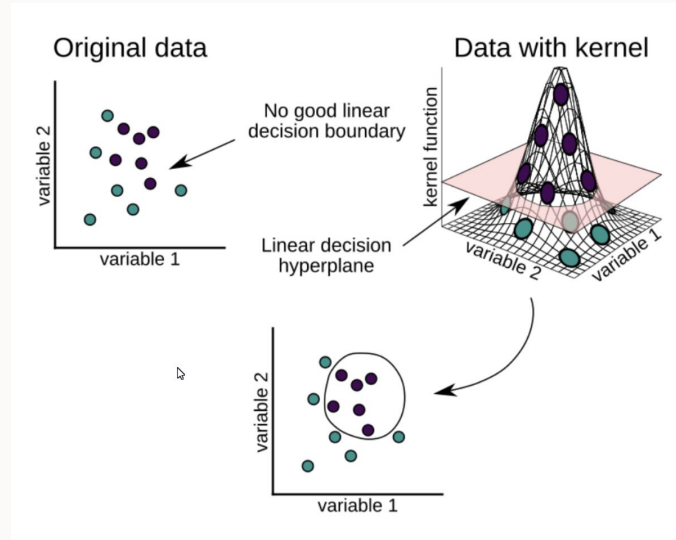


$$\max_{\alpha} \sum_{i=1}^M \alpha_i - \frac{1}{2} \sum_{i,j=1}^M y^{(i)} y^{(j)} \alpha_i \alpha_j K(x^{(i)}, x^{(j)})$$

subject to  $0 \leq \alpha_i \leq C$  for all  $i$ , and  $\sum_{i=1}^M \alpha_i y^{(i)} = 0$ .



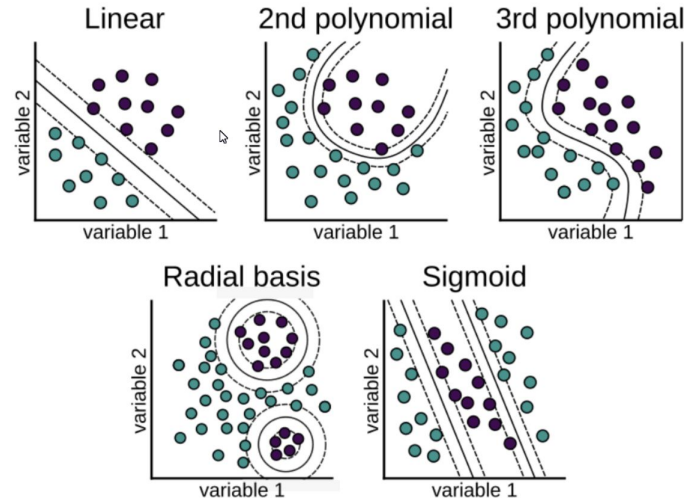
# Función de Kernel



**Conjunto de funciones** que permite **transformar** el espacio de características con el que trabajamos



# Función de Kernel



Existen varios tipos de Kernel para **distintas aplicaciones**